TECH CHALLENGE · FASE 2 · POSTECH DTAT

vinoRossi

Classificando a qualidade de vinhos com Machine Learning

Storytelling da Análise Exploratória de Dados

github.com/marcosrossi-eco/Wine-Quality-ML

Vinho tinto · 1.143 amostras · 11 variáveis físico-químicas

Prever a nota do vinho a partir da química, sem depender só do degustador

Contexto

A avaliação sensorial é valiosa, mas subjetiva e lenta. Medidas físico-químicas, coletadas durante a produção, podem apoiar enólogos na padronização da qualidade.

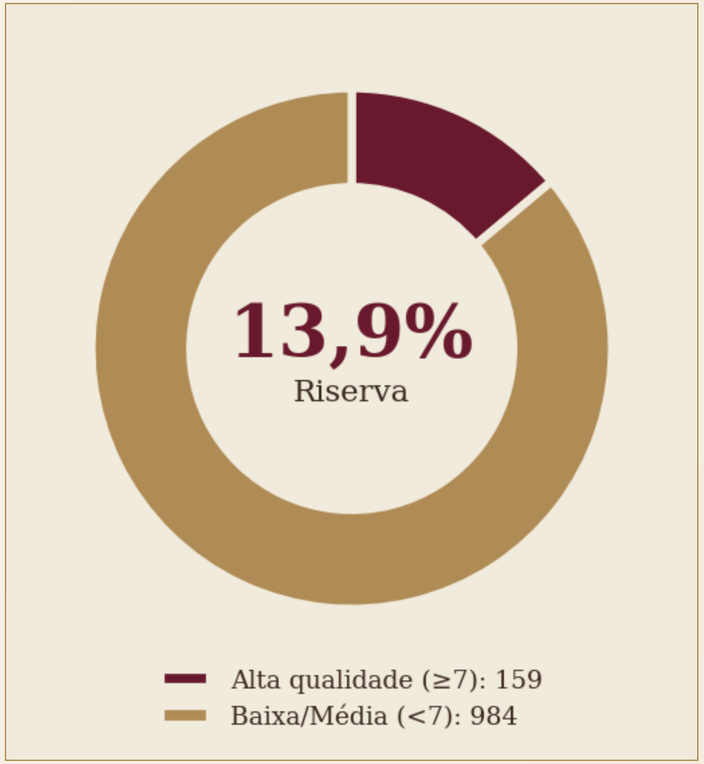
Variável alvo

quality (nota 0 a 10 dada por especialistas), transformada em classificação binária: **Riserva** (nota ≥ 7, classe 1) e **Padrão** (nota < 7, classe 0).

Base de dados

Wine Quality Dataset (WineQT.csv, Kaggle), vinho tinto: 11 variáveis numéricas (acidez fixa e volátil, ácido cítrico, açúcar residual, cloretos, SO_2 livre e total, densidade, pH, sulfatos, álcool) e a nota.

1.143	11	0	13,9%
amostras	variáveis	nulos	Riserva



Só 13,9% dos vinhos são Riserva, e várias medidas têm cauda longa

Desbalanceamento

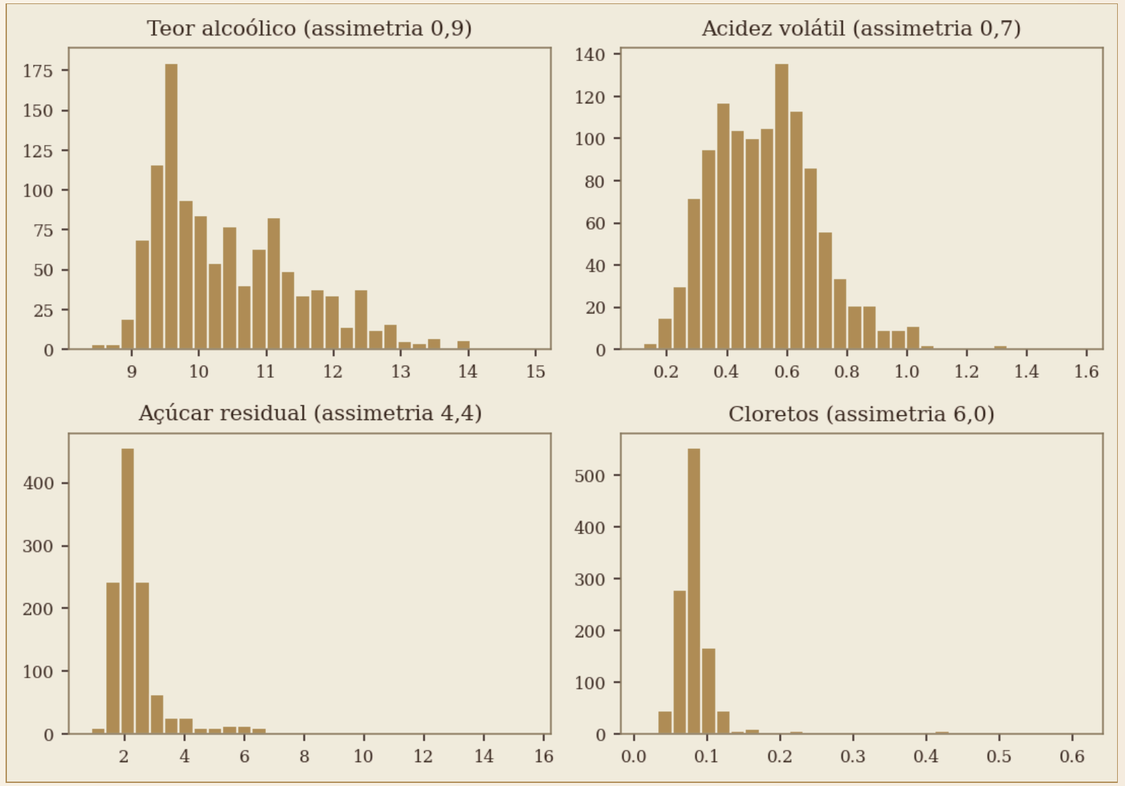
Proporção de 6,2 Padrão para 1 Riserva. Um classificador que sempre responde “Padrão” acerta 86,1% e não encontra nenhum Riserva. Por isso, acurácia sozinha engana: avaliamos precisão, recall, F1 e AUC.

Distribuições

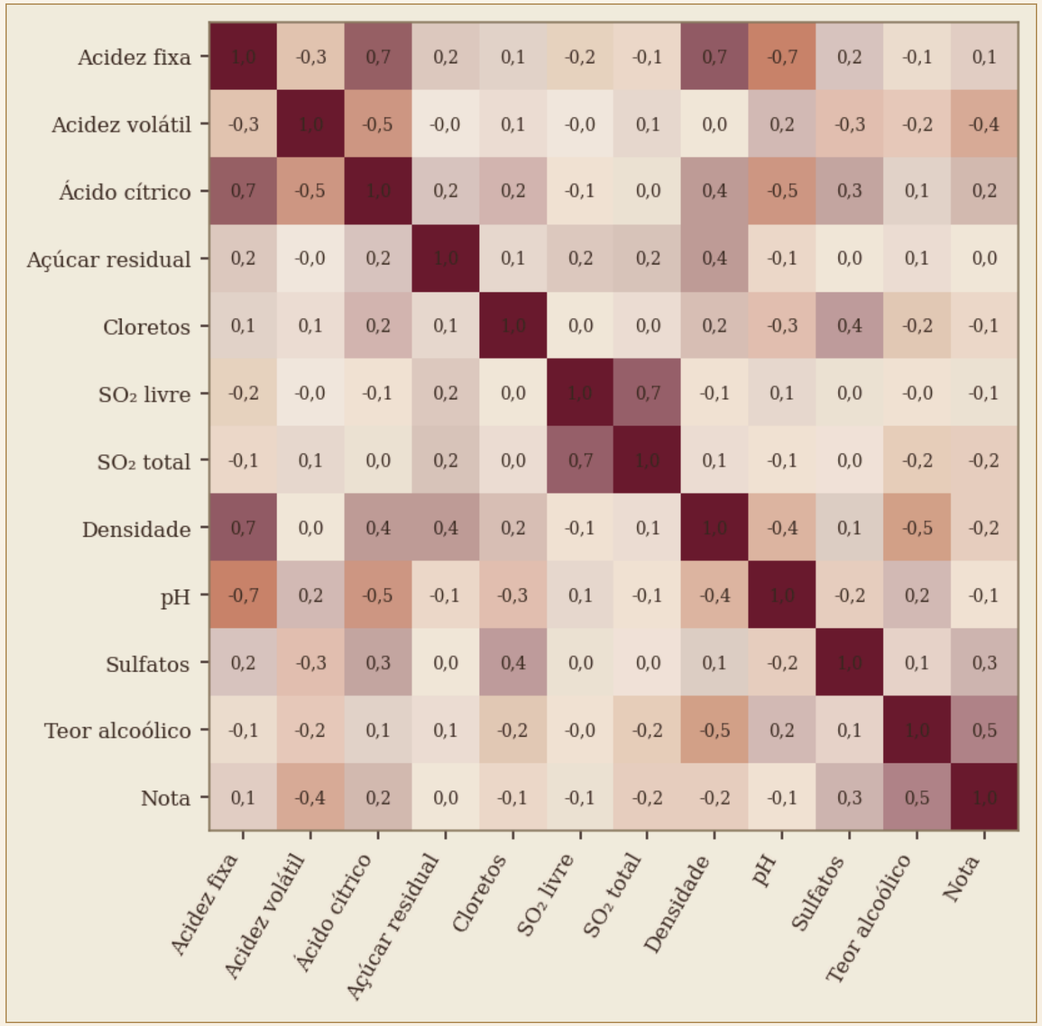
Açúcar residual (assimetria 4,4) e cloretos (6,0) concentram a maioria dos lotes em faixa estreita, com poucos valores muito altos. Álcool também é assimétrico à direita (0,9).

Consequência

Escalas e caudas muito diferentes pedem padronização para o modelo linear; modelos de árvores toleram melhor esse comportamento.



Álcool e acidez volátil são as medidas mais ligadas à qualidade



Com a classe Riserva

Álcool +0,40 e sulfatos +0,21: lotes mais maduros e melhor conservados. Acidez volátil -0,30: excesso indica ácido acético (defeito de vinagre). Ácido cítrico +0,25: contribui com frescor.

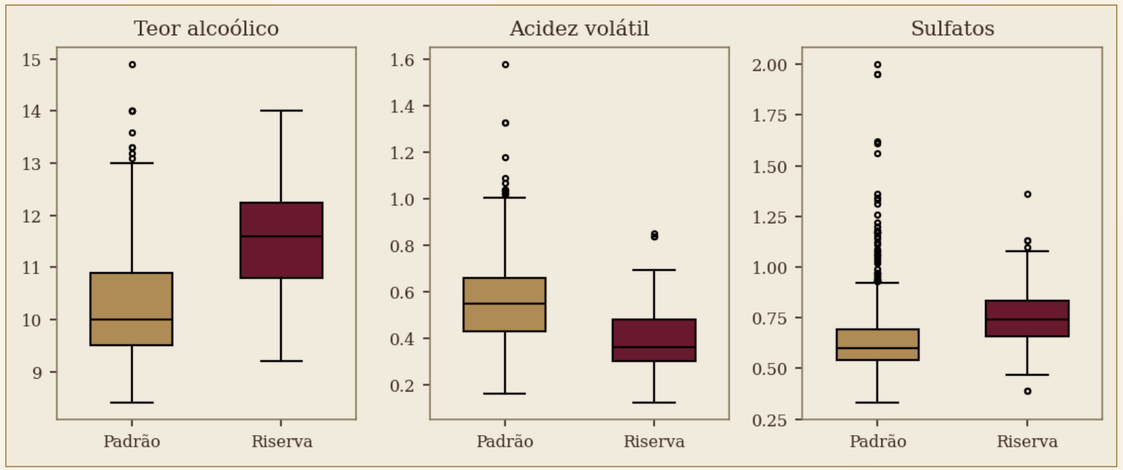
Entre as próprias variáveis

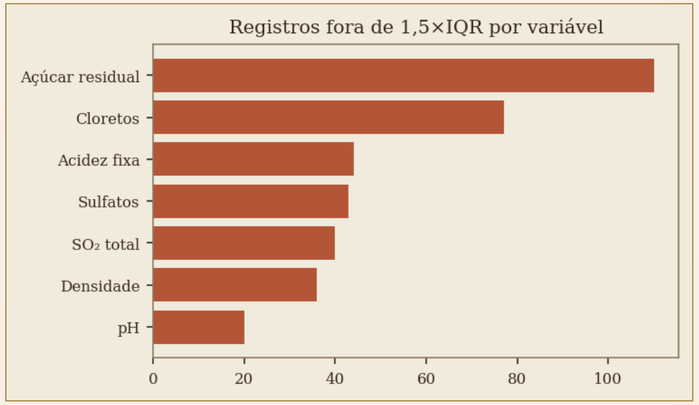
Acidez fixa × pH -0,69 (mais ácido, pH menor); acidez fixa × ácido cítrico +0,67 (o cítrico é um ácido fixo); acidez fixa × densidade +0,68; SO_2 livre × total +0,66 (o livre é parte do total); álcool × densidade -0,49 (o álcool é menos denso que a água).

Implicação

Há redundância entre acidez, pH e densidade (multicolinearidade). Mantivemos todas: árvores lidam bem com isso, e na regressão logística a padronização estabiliza os pesos.

Riserva tem mais álcool e sulfatos e menos acidez volátil





O perfil que separa as classes

Mediana de álcool: 11,6% (Riserva) contra 10,0% (Padrão). Acidez volátil: 0,36 contra 0,55. Sulfatos: 0,74 contra 0,60.

Outliers

295 registros (25,8%) têm ao menos uma medida fora de 1,5×IQR, sobretudo em açúcar residual, cloretos e acidez fixa. São valores quimicamente plausíveis (vinhos mais doces ou mais salinos), não erros de registro; mantidos.

Inconsistências

Nenhum valor ausente ou impossível. 125 registros têm medidas idênticas a outro e foram mantidos nesta versão.

Dados prontos para comparar modelos de forma justa

Faltantes e duplicados

Zero nulos. 125 linhas têm medidas idênticas a outra e foram mantidas nesta versão; remover duplicados fica como teste de robustez. Base: 1.143 amostras.

Variável-alvo e medidas

target = 1 se a nota é ≥ 7, senão 0. As 11 medidas químicas entram sem criação de variáveis novas, mantendo o modelo simples e interpretável.

Padronização

StandardScaler ajustado só no treino e aplicado ao teste, para não vazar informação. Usado na regressão logística; o Random Forest recebe os dados originais.

Divisão treino/teste

80/20 estratificada (random_state 42): 914 treino e 229 teste, preservando a proporção de Riserva (32 no teste).

Random Forest encontra 68,8% dos vinhos Riserva; a regressão logística, 34,4%

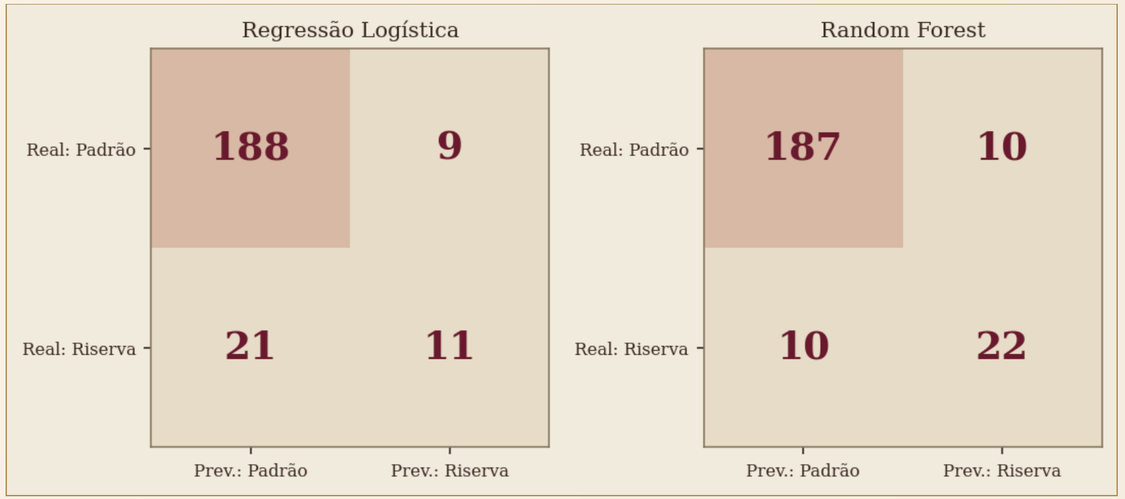
	Acurácia	Precisão	Recall	F1	AUC
Baseline (sempre Padrão)	86,0%	0,0%	0,0%	0,0%	0,500
Regressão Logística	86,9%	55,0%	34,4%	42,3%	0,847
Random Forest	91,3%	68,8%	68,8%	68,8%	0,911

Modelos

Regressão Logística (`max_iter=500`, dados padronizados, sem pesos de classe) e Random Forest (200 árvores, `class_weight=balanced`), ambos com random_state 42. Métricas da classe Riserva no teste de 229 vinhos, limiar 0,5.

Leitura

O Random Forest lidera: encontra 68,8% dos Riservas com precisão de 68,8%. A Regressão Logística encontra só 34,4% (precisão 55,0%), pois não compensa o desbalanceamento das classes.



Álcool, sulfatos e ácido cítrico pesam mais; acidez volátil é o alerta



Teor alcoólico · Ponto de colheita e maturação

Vinhos de maior teor alcoólico tendem a vir de uvas mais maduras. Monitorar o ponto ideal de colheita é a alavanca mais forte.

Sulfatos · Conservação e estabilidade

Sulfatos ajudam a proteger o vinho. Padronizar a dosagem reduz a variação entre lotes.

Ácido cítrico · Frescor e equilíbrio

O ácido cítrico dá frescor. Ajustes pontuais corrigem lotes sem vivacidade.

Acidez volátil · Higiene e fermentação

Acidez volátil alta sinaliza contaminação (vinagre). Limpeza rigorosa e controle da fermentação evitam o descarte de lotes.

Limites

Um único conjunto de teste (32 Riservas) e limiar fixo em 0,5 geram incerteza. Próximos passos: validação cruzada, ajuste de limiar, outros modelos e dados de vinho branco e de outras origens.

REPOSITÓRIO

Código, base e materiais para reproduzir esta análise

GitHub
github.com/marcosrossi-eco/Wine-Quality-ML
Pasta do projeto: **wine-quality-classification/**

data/WineQT.csv
Base utilizada (1.143 amostras, 11 medidas químicas e a nota).

notebooks/eda_wine_quality.ipynb
Notebook com a análise exploratória, os modelos e a avaliação.

results/
Gráficos gerados pelo notebook: correlações, matrizes de confusão e importância das variáveis.

README.md
Descrição do projeto.

Apresentação executiva
Este storytelling da análise exploratória (PDF).

Vídeo executivo
Resumo em linguagem de negócio, com até 5 minutos, para diretores.

Como reproduzir
Abrir o notebook e executar as células em ordem; o caminho ../data/WineQT.csv é relativo à pasta notebooks/.